

**İbrahim Nuryağınlı****25490221001****Necmettin Erbakan Üniversitesi****Konya Organize Sanayi Bölgesi Meslek Yüksek Okulu**

YZO 106 – İleri Düzey Makine Öğrenmesi

**Proje Önerisi***Teslim Tarihi: 09.04.2026*

## **Agro-Çevresel Simülasyon Verisiyle Bitki Sağlığının Çok Hedefli Makine Öğrenmesi ile Tahmini: Başarısızlık, Uygunluk Skoru ve Stres Düzeyi Analizi**

### **1. Giriş**

Tarımsal üretimde verimlilik ve sürdürülebilirlik, dünya genelinde artan nüfusun gıda ihtiyacını karşılayabilmek açısından kritik bir önem taşımaktadır. Bitkilerin yetiştirme ortamlarındaki toprak koşulları; nem, sıcaklık, pH dengesi ve besin elementi içeriği gibi fiziksel ve kimyasal parametreler, bitki büyümesini doğrudan etkilemektedir. Bu parametrelerdeki sapmaların zamanında tespit edilmesi, tarımsal kayıpları önlemek ve kaynakları verimli kullanmak bakımından son derece önemlidir.

Son yıllarda Nesnelerin İnterneti (IoT) teknolojilerinin tarım alanına entegrasyonu ile birlikte, tarla sensörleri aracılığıyla toprak ve çevre verileri gerçek zamanlı olarak toplanabilmektedir. Bu veri zenginliği, geleneksel gözlem yöntemlerinin ötesinde, veri odaklı analitik yaklaşımlar için eşsiz bir fırsat sunmaktadır. Makine öğrenmesi (MO) algoritmaları, bu tür çok değişkenli ve büyük ölçekli veri kümelerinden örüntüler öğrenerek bitki sağlığına ilişkin öngöründe bulunabilecek güçlü araçlar olarak öne çıkmaktadır.

Bu proje; toprak sensörlerinden elde edilen verileri kullanan bir makine öğrenmesi sistemi geliştirmeyi hedeflemektedir. Çalışma kapsamında üç ayrı tahmin görevi ele alınacaktır: bitkinin hayatta kalıp kalmayacağına ikili sınıflandırma yöntemiyle tahmin edilmesi, toprağın bitkiye uygunluğunu ifade eden sürekli bir puanın regresyon modeliyle kestirimi ve bitkinin stres düzeyinin çok sınıflı sınıflandırma yöntemiyle belirlenmesi. Elde edilecek bulgular, hem tarımsal karar destek sistemlerine hem de akıllı tarım uygulamalarına doğrudan katkı sağlayabilecek niteliktedir.

### **2. Problem Tanımı**

Tarımsal üretim süreçlerinde bitki kayıpları; toprak koşullarındaki anlık veya kümülatif olumsuzluklar nedeniyle sıkça yaşanmaktadır. Mevcut izleme sistemleri çoğunlukla manuel gözleme ya da rutin numune analizlerine dayanmakta; bu durum geç teşhis, yüksek

işgücü maliyeti ve müdahale gecikmesi gibi ciddi sorunlara yol açmaktadır. Tarihsel sensör verilerinden öğrenen bir tahmin sistemi, bu boşluğu doldurmak için güçlü bir çözüm alternatifi sunmaktadır.

Araştırmanın temel problemi üç bileşenden oluşmaktadır:

- Hangi toprak sensör değerlerinin bitki ölümüne (başarısızlık) yol açtığından önceden tahmin edilememesi,
- Toprak uygunluk skorunun (suitability\_score) sayısal olarak kestirimi için güvenilir bir regresyon modelinin eksikliği,
- Bitki stres düzeyinin (sağlıklı, hafif stres, kritik stres) otomatik olarak sınıflandırılmasını sağlayan bir sistemin bulunmamasıdır.

Bu üç sorunun çözülmesi, hem erkenden müdahale imkânı sağlayarak bitki kayıplarını azaltacak hem de tarımsal karar verme süreçlerini veri odaklı bir zemine oturtacaktır. Ayrıca mevcut modellerin çoğunun tek bir hedef değişkeni ele alması, çok hedefli entegre bir yaklaşımın geliştirilmesini literatür açısından da değerli kılmaktadır.

### 3. Amaçlar

Bu çalışmanın temel amacı, toprak sensörlerinden derlenen çok değişkenli veri üzerinden bitki sağlığını üç farklı boyutta tahmin eden makine öğrenmesi modelleri geliştirmektir. Çalışmanın spesifik amaçları şöyle sıralanabilir:

1. Görev 1 – Başarısızlık Tahmini (İkili Sınıflandırma): Bitkilerin çevresel ve toprak koşullarına dayalı olarak hayatta kalıp kalmayacağını (failure\_flag: 0/1) yüksek doğrulukla sınıflandırmak ve tahmin edici değişkenleri Açıklanabilir Yapay Zeka (XAI/SHAP) yöntemleriyle görselleştirmek.
2. Görev 2 – Uygunluk Skoru Tahmini (Regresyon): Toprak sensörü ölçümlerini girdi olarak kullanarak toprağın bitkiye uygunluğunu ifade eden sürekli sayısal skoru (suitability\_score) tahmin etmek ve modelin açıklama gücünü  $R^2$  ve MSE metrikleriyle değerlendirmek.
3. Görev 3 – Stres Düzeyi Tahmini (Çok Sınıflı Sınıflandırma): Bitkinin üç farklı stres durumunu (Sağlıklı, Hafif Stres, Kritik Stres) sensör girdilerine göre sınıflandıran bir model kurmak ve sınıflar arası ayrım başarısını karmaşıklık matrisiyle raporlamak.

Tüm görevlerde aşırı öğrenmeyi önlemek amacıyla hiperparametre optimizasyonu (GridSearchCV) uygulanacak; modeller rastgele orman (Random Forest) mimarisine dayandırılacaktır. Akademik katkı açısından, tek bir pipeline tasarımı altında üç farklı görevin entegre biçimde ele alınması ve SHAP tabanlı yorumlanabilirlik analizinin eklenmesi çalışmayı özgün kılmaktadır.

### 4. Veri Seti ve Değişkenler

Projede kullanılacak veri seti, Kaggle platformunda niladriroy0 kullanıcısı tarafından paylaşılan "Agro-Environmental Stress & Failure Simulation" başlıklı açık erişimli veri setidir (Roy, 2024). Veri seti, çeşitli tarımsal çevre koşullarını simüle eden sentetik

kayıtlardan oluşmakta olup farklı bitki türleri ve toprak tipi kombinasyonlarını kapsamaktadır. Gerçek saha ölçümlerinin yetersiz kaldığı durumlarda kontrollü bir değerlendirme ortamı oluşturmak amacıyla sentetik simülasyon verilerinin tarım araştırmalarında kullanımı yaygın bir yöntem olarak kabul görmektedir (Van Klompenburg vd., 2020). Veri seti yapılandırılmış CSV formatında sunulmakta; hem sayısal hem de kategorik değişkenler ile üç farklı hedef sütunu içermektedir.

Bağımlı değişkenler (hedef sütunlar) şunlardır:

- `failure_flag` (0 = Yaşıyor, 1 = Öldü): Bitkinin belirli toprak koşullarında hayatta kalıp kalmadığını gösteren ikili değişken.
- `suitability_score` (sürekli, sayısal): Toprağın söz konusu bitki türü için uygunluk derecesini yansıtan 0–100 aralığında bir puan.
- `stress_level` (0 = Sağlıklı, 1 = Hafif Stres, 2 = Kritik Stres): Bitkinin stres kategorisini gösteren sıralı sınıf değişkeni.

Bağımsız değişkenler (girdi özellikleri), yüksek düzeyde türetilmiş veya yorum gerektiren nitelikteki sütunlar (`location_id`, `moisture_regime`, `thermal_regime`, `ph_stress_flag`, `nutrient_balance`, `moisture_limit_dry`, `moisture_limit_wet`, `bulk_density`, `organic_matter_pct`, `cation_exchange_capacity`, `buffering_capacity`) analizden çıkarıldıktan sonra kalan doğrudan çevre ve toprak ölçümlerinden oluşmaktadır. Bu değişkenler; toprak nemi, toprak ve hava sıcaklığı, pH, elektriksel iletkenlik (EC), ışık yoğunluğu, yağış miktarı ve bitki türü gibi sayısal ve kategorik nitelikte çok sayıda özelliği kapsamaktadır. Veri setinde ayrıca her kaydın hangi coğrafi veya deneysel koşula ait olduğunu belirten lokasyon tanımlayıcısı (`location_id`) mevcuttur; ancak bu sütun model girdisi olarak kullanılmamıştır.

Sayısal değişkenlere eksik değer atama ve standartlaştırma (StandardScaler), kategorik değişkenlere ise en sık değer ile doldurma ve one-hot kodlama (OneHotEncoder) uygulanmıştır. Tüm ön işlem adımları, sızıntıyı önlemek amacıyla sklearn Pipeline ve ColumnTransformer nesneleri içinde bütünleşik biçimde yönetilmiştir.

Örnek veri yapısı (temsili):

| <code>soil_temp</code> (°C) | <code>soil_moisture</code> (%) | <code>pH</code> | <code>EC</code> (mS/cm) | <code>plant_type</code> |
|-----------------------------|--------------------------------|-----------------|-------------------------|-------------------------|
| 23.4                        | 42.1                           | 6.8             | 1.25                    | domates                 |
| 31.7                        | 18.6                           | 5.3             | 2.87                    | buğday                  |

Tablo 1. Veri setinden temsili giriş değişkenleri örneği.

## 5. Ön Literatür Taraması

Toprak ve çevresel verilerden faydalanarak bitki sağlığını tahmin etmeye yönelik çalışmalar, makine öğrenmesinin tarım alanındaki uygulamalarının en aktif araştırma kollarından birini oluşturmaktadır.

Liakos ve diğerleri (2018), tarımsal alanlarda makine öğrenmesi uygulamalarını sistematik biçimde ele alan kapsamlı bir derleme sunmuştur. Çalışmada bitki hastalığı tespiti, verim tahmini ve toprak sınıflandırması gibi başlıklar incelenmiş; Destek Vektör Makineleri (SVM) ve yapay sinir ağlarının bu görevlerde yaygın biçimde tercih edildiği görülmüştür. Bununla birlikte, yorumlanabilirlik ve çok hedefli öğrenme konularındaki eksiklikler de vurgulanmıştır (Liakos vd., 2018).

Rashid ve diğerleri (2021) tarafından gerçekleştirilen çalışmada IoT sensörlerinden toplanan toprak verilerinin Random Forest algoritmasıyla işlenmesiyle bitki stres koşullarının sınıflandırıldığı ve %87 doğruluk oranına ulaşıldığı raporlanmıştır. Ancak söz konusu çalışma yalnızca ikili bir sınıflandırma senaryosunu ele almış; regresyon ve çok sınıflı görevleri aynı pipeline altında bütünleştiren entegre bir yaklaşım sunmamıştır (Rashid vd., 2021).

Açıklanabilir yapay zeka (XAI) alanında Lundberg ve Lee (2017) tarafından geliştirilen SHAP (SHapley Additive exPlanations) çerçevesi, model tahminlerinin özellik düzeyinde yorumlanmasına imkân tanımaktadır. SHAP, tarımsal modellerde hangi toprak parametrelerinin tahmin üzerinde belirleyici olduğunu görselleştirmek için giderek daha yaygın kullanılmaktadır (Lundberg & Lee, 2017). Mevcut çalışmaların büyük çoğunluğu SHAP'ı bağımsız bir analiz adımı olarak eklemekte; bunu çok hedefli bir ML sistemiyle bütünleştiren entegre tasarımlara ise nadiren rastlanmaktadır.

Moshou ve diğerleri (2014) bitki su stresinin erken tespitinde sınıflandırma algoritmalarının etkinliğini araştırmış; ensemble yöntemlerinin tek model yaklaşımlarına kıyasla daha kararlı sonuçlar ürettiğini ortaya koymuştur (Moshou vd., 2014). Van Klompenburg ve diğerleri (2020) ise mahsul verimi tahmininde makine öğrenmesi yöntemlerini karşılaştırmış; Random Forest ve Gradient Boosting algoritmalarının tutarlı biçimde yüksek performans sergilediğini göstermiştir (Van Klompenburg vd., 2020).

Mevcut literatür incelendiğinde şu eksiklikler öne çıkmaktadır: (1) aynı veri seti üzerinde sınıflandırma, regresyon ve çok sınıflı sınıflandırma görevlerini tek bir pipeline içinde ele alan entegre çalışma sayısı oldukça azdır; (2) hiperparametre optimizasyonunun XAI analiziyle birlikte sunulduğu kapsamlı karşılaştırmalı çalışmalar sınırlı kalmaktadır; (3) çalışmaların önemli bir kısmı sonuçların yorumlanabilirliğini göz ardı etmektedir. Önerilen proje, bu boşlukları doldurmayı ve söz konusu üç görevi modüler, yeniden kullanılabilir ve yorumlanabilir bir makine öğrenmesi sistemi çatısı altında birleştirmeyi hedeflemektedir.

**Kaynakça**

4. Liakos, K. G., Busato, P., Moshou, D., Pearson, S., & Bochtis, D. (2018). Machine learning in agriculture: A review. *Sensors*, 18(8), 2674. <https://doi.org/10.3390/s18082674>
5. Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.
6. Moshou, D., Bravo, C., Oberti, R., West, J. S., Ramon, H., Vougioukas, S., & Bochtis, D. (2014). Intelligent multi-sensor system for the detection and treatment of fungal diseases in arable crops. *Biosystems Engineering*, 117, 94–103. <https://doi.org/10.1016/j.biosystemseng.2013.05.001>
7. Rashid, M., Bari, B. S., Yusup, Y., Kamaruddin, M. A., & Khan, N. (2021). A comprehensive review of crop yield prediction using machine learning approaches with special emphasis on palm oil yield prediction. *IEEE Access*, 9, 63406–63439. <https://doi.org/10.1109/ACCESS.2021.3075159>
8. Roy, N. (2024). Agro-environmental stress & failure simulation [Veri seti]. Kaggle. <https://www.kaggle.com/datasets/niladriroy0/agro-environmental-dataset>
9. Van Klompenburg, T., Kassahun, A., & Catal, C. (2020). Crop yield prediction using machine learning: A systematic literature review. *Computers and Electronics in Agriculture*, 177, 105709. <https://doi.org/10.1016/j.compag.2020.105709>